



INSTITUTO POLITÉCNICO NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO



Práctica 2.- Modelo Entidad-Relación-Extendido

Lectura y resumen de tres artículos

Ejercicio 3

Desarrollo

Avalos Hernandez Joshua Jasiel

Bravo Mina Liam Valapai

Antonio Navarro Domínguez

Grupo: 3CV3

Profesor: Gabriel Hurtado Avilés

Artículo 1. Datos sísmicos

Villa Vargas, J. M., Hurtado Avilés, G., y Climent Hernández, J. A. (2026). *Cuando México tiembla: la historia contada por los datos*.

El artículo aborda el problema de hacer que la información sísmica de México sea más accesible y fácil de analizar. Los sismos son fenómenos naturales impredecibles que pueden tener consecuencias importantes para la población y el territorio. México presenta un riesgo sísmico considerable debido a su ubicación y a la interacción de cinco placas tectónicas. Aunque el Servicio Sismológico Nacional (SSN) cuenta con información detallada de los sismos ocurridos en el país desde 1900, los autores señalan que estos datos pueden resultar demasiado técnicos, poco amigables visualmente o difíciles de manejar para algunas personas. Por ello, el proyecto propone transformar los datos sísmicos en representaciones visuales mediante un sistema web interactivo. Los datos utilizados provienen principalmente del **Servicio Sismológico Nacional** y del **Instituto Nacional de Estadística y Geografía (INEGI)**. Del SSN se obtiene un archivo **CSV** con más de 300 000 sismos registrados en México desde 1900. De INEGI se utilizan dos archivos CSV: uno correspondiente al **Censo de Población y Vivienda 2020** y otro de los **Censos Económicos**. Antes de introducir estos datos en la base de datos, se realiza un proceso de validación mediante un programa desarrollado en Python. Este programa identifica campos vacíos, coordenadas inconsistentes y formatos incompatibles, elimina los registros inválidos y genera un archivo SQL con los datos validados. Posteriormente, la información se carga en PostgreSQL, donde se organiza como un **data warehouse** que integra los datos sísmicos, demográficos y económicos.

En cuanto al modelado de la información, el sistema organiza los datos de los **sismos**, la **población** y la **economía**, permitiendo relacionar estas fuentes para realizar análisis más amplios. Los registros sísmicos contienen información relevante como la magnitud, profundidad y ubicación. A partir de la información almacenada se generan diferentes tipos de visualizaciones: mapas interactivos, gráficos estadísticos, mapas de calor y reportes personalizados. Estos últimos pueden filtrarse por periodo de tiempo, magnitud, localidad, profundidad, número de habitantes y producción económica. De esta manera, el sistema permite combinar las características de los eventos sísmicos con información territorial, demográfica y económica.

El sistema puede responder preguntas relacionadas con la distribución y comportamiento de los sismos. Por ejemplo, permite identificar dónde ocurrieron determinados eventos, analizar sismos por estado o por año, observar la concentración de actividad sísmica mediante mapas de calor y localizar poblaciones densamente habitadas cercanas a los epicentros. También puede utilizarse para relacionar las zonas sísmicas con datos de población y economía, lo que puede apoyar actividades como la planeación territorial, identificación de zonas de peligro, diseño de rutas de evacuación y elaboración de planes

de acción. En investigación, los reportes pueden facilitar el análisis de patrones y las comparaciones de cambios en la actividad sísmica a lo largo de los datos disponibles. Como limitación, los autores reconocen que la implementación del sistema puede resultar complicada para usuarios con poco o ningún dominio de las herramientas utilizadas. Para facilitar su distribución, utilizan **Docker Compose**, dividiendo el sistema en dos contenedores interconectados: uno para la base de datos y otro para el servidor web PHP. El sistema puede distribuirse mediante un repositorio público de GitHub junto con su código fuente y archivos de configuración. Finalmente, los autores proponen como trabajo futuro incorporar **visualizaciones en 3D**, agregar más fuentes de datos oficiales e integrar el sistema con plataformas de **alerta temprana**.

Artículo 2. Consumo de agua en la Ciudad de México.

El artículo presenta la construcción de un **Data Warehouse para consultar y analizar territorialmente el consumo de agua en la Ciudad de México**. El problema que aborda es que existen datos públicos sobre el consumo de agua proporcionados por SACMEX, pero se encuentran en formatos poco accesibles y sin herramientas suficientes para realizar consultas y análisis de manera sencilla. Esto es importante debido a la problemática del agua en la Ciudad de México, relacionada con la sobreexplotación de los acuíferos, las fugas en la red y el crecimiento de la población. Por ello, los autores buscan transformar los datos dispersos en información que pueda consultarse por territorio, periodo y nivel de desarrollo. El sistema está pensado para ciudadanos, investigadores, periodistas, organizaciones civiles y servidores públicos que necesiten analizar la demanda de agua.

Problema que aborda y por qué importa

El principal problema es la dificultad para utilizar los datos abiertos de consumo de agua de la Ciudad de México como información analítica. Aunque los datos existen, su formato original no facilita las consultas territoriales ni la visualización de patrones. El trabajo propone integrar estos datos en un repositorio dimensional que permita realizar búsquedas por alcaldía, colonia y periodo, además de representar los resultados geográficamente.

La importancia radica en que una mejor organización de la información permite analizar cómo se distribuye el consumo de agua y detectar diferencias entre zonas. El sistema puede utilizarse para realizar diagnósticos urbanos, investigación y monitoreo ciudadano. Los autores consolidaron finalmente **70,886 registros de consumo correspondientes a 1,553 ubicaciones** dentro de las 16 alcaldías de la Ciudad de México.

Origen, formato y preparación de los datos

La principal fuente de información fue **SACMEX**, específicamente el recurso abierto denominado *Consumo Agua (1er Semestre 2019)*, publicado en el Portal de Datos Abiertos de la Ciudad de México. Los datos se encontraban en archivos **CSV** y contenían información correspondiente a los primeros tres bimestres de 2019. El archivo original tenía **71,102 registros**.

Para poder utilizar los datos fue necesario aplicar un proceso **ETL (Extract, Transform, Load)**. Primero se extrajeron los archivos CSV de SACMEX. Después se realizó una etapa de validación y limpieza para identificar campos vacíos, coordenadas inconsistentes y formatos incompatibles. Posteriormente, los datos se cargaron temporalmente mediante tablas de *staging* y se obtuvieron los valores necesarios para construir las dimensiones. Finalmente, mediante relaciones entre los datos temporales y las dimensiones, se poblaron las tablas de hechos.

Durante la limpieza se descartaron **216 registros**, equivalentes al 0.30 % de los datos originales. Estos registros tenían valores NA en los campos territoriales y no podían relacionarse correctamente con las dimensiones. Los **70,886 registros restantes**, equivalentes al 99.70 %, fueron cargados al Data Warehouse.

Además de los datos de consumo de SACMEX, el sistema integra una serie meteorológica proveniente de **Open-Meteo** y utiliza **OpenStreetMap** como base cartográfica para la visualización.

Cómo se modeló la información

La información se organizó mediante un **modelo dimensional de tipo estrella (star schema)** implementado en PostgreSQL. El modelo contiene **dos tablas de hechos**:

- **fact_consumo_agua**: almacena los datos relacionados con el consumo de agua.
- **fact_clima**: almacena la información de la serie climática.

Ambas se relacionan mediante una dimensión temporal compartida.

El modelo utiliza tres dimensiones principales:

- **dim_tiempo**: contiene la fecha, año y bimestre.
- **dim_ubicacion**: contiene alcaldía, colonia, latitud y longitud.
- **dim_indice_des**: contiene el nivel de desarrollo de la zona.

El índice de desarrollo tiene cuatro categorías: **alto, medio, bajo y popular**.

El nivel de detalle de la tabla **fact_consumo_agua** corresponde a **una manzana para un periodo de facturación**. A partir de estas relaciones se pueden realizar agregaciones

por colonia, alcaldía, periodo y nivel de desarrollo. El almacén terminó con 70,886 registros en la tabla de consumo, 1,553 ubicaciones, cuatro niveles del índice de desarrollo y una dimensión temporal de 181 registros diarios, utilizada principalmente para integrar los datos climáticos.

Además del Data Warehouse, los autores realizan una transformación mediante **R2RML** para representar la información como un grafo de conocimiento RDF. Esto permite realizar consultas territoriales mediante recorridos del grafo, por ejemplo, encontrar colonias cercanas a otra colonia y ordenar sus consumos.

Preguntas que puede responder el sistema

El sistema permite realizar consultas combinando diferentes dimensiones. Entre las preguntas que puede responder se encuentran:

- ¿Cuánto consumo de agua existe en una determinada alcaldía?
- ¿Cuánto consume una colonia específica?
- ¿Cómo cambia el consumo entre los diferentes bimestres disponibles?
- ¿Qué alcaldías presentan mayor consumo total?
- ¿Cuál es el consumo promedio por colonia?
- ¿Cómo se distribuye el consumo de acuerdo con el nivel de desarrollo?
- ¿Qué colonias se encuentran cerca de una determinada colonia?
- ¿Qué zonas presentan valores de consumo considerados atípicos?
- ¿Dónde se concentra territorialmente el consumo de agua?

Las consultas pueden realizarse utilizando filtros de **año, bimestre, alcaldía y colonia**, y los resultados pueden representarse mediante gráficos y un mapa coroplético. También existe un módulo exploratorio que identifica zonas cuyo consumo se aleja considerablemente del comportamiento de otras colonias de la misma alcaldía.

El análisis realizado por los autores encontró que **Cuauhtémoc y Miguel Hidalgo presentan los mayores consumos totales** dentro de los datos disponibles. Sin embargo, el artículo aclara que el consumo total no debe interpretarse como consumo por habitante, debido a diferencias como la actividad comercial entre las alcaldías.

5. Limitaciones y trabajo futuro

Los autores reconocen varias limitaciones. La primera es temporal: los datos de SACMEX corresponden solamente a **los tres primeros bimestres de 2019**, por lo que no permiten

realizar un análisis de varios años ni establecer adecuadamente una relación entre consumo y temporadas secas o lluviosas. La comparación climática se basa únicamente en tres puntos agregados.

Otra limitación corresponde al módulo de detección de consumo atípico. Debido a que los datos disponibles no contienen etiquetas reales de fugas o anomalías, su evaluación utiliza **perturbaciones sintéticas**, por lo que los resultados no permiten afirmar que el sistema detecte fugas reales.

También existe una limitación geográfica: las colonias se representan mediante **centroides** y no mediante polígonos oficiales. Por esta razón, cuando el sistema identifica colonias cercanas, se trata de una proximidad de hasta 1.5 km y no de una relación exacta entre límites territoriales. Finalmente, la relación observada entre el nivel de desarrollo y el consumo es solamente descriptiva; los autores señalan que para explicar las causas socioeconómicas sería necesario incorporar información externa.

Como trabajo futuro, los autores proponen crear un **triple store permanente con un punto de consulta SPARQL público**, sustituir los centroides por polígonos oficiales de las colonias, mejorar la interoperabilidad de los identificadores territoriales y volver a evaluar el módulo de anomalías cuando existan datos reales y etiquetados de fugas. También plantean aplicar la metodología a otros problemas urbanos, como movilidad, calidad del aire y riesgo sísmico.

Artículo 3. Obra publica municipal.

González Casiano, U., Maldonado Mejía, M. T., y Hurtado Avilés, G.

El artículo aborda el problema de la dificultad para administrar y analizar la información relacionada con las obras públicas municipales. Los departamentos encargados de estas obras manejan contratistas, presupuestos, supervisores, fotografías de avance, reportes mensuales y procesos de entrega, pero esta información suele encontrarse distribuida entre hojas de cálculo, archivos y sistemas transaccionales aislados. Esto dificulta realizar análisis históricos, detectar retrasos oportunamente y facilitar la participación ciudadana. Por esta razón, los autores presentan un prototipo de **Data Warehouse dimensional** para el monitoreo geoespacial de obras públicas municipales, complementado con almacenamiento de objetos para guardar evidencias como fotografías y documentos PDF. El prototipo se plantea para el municipio de Temascaltepec, Estado de México, aunque los autores aclaran que los resultados presentados utilizan datos sintéticos y no representan el comportamiento real del municipio.

Los datos del sistema incluyen información estructurada de las obras y evidencias no estructuradas. Desde la aplicación web se pueden registrar datos como texto, coordenadas y cantidades económicas, además de archivos **JPG, PNG y PDF**. Estos

archivos se almacenan en **Cloudflare R2**, un servicio compatible con la API de Amazon S3, mientras que la información estructurada se almacena en PostgreSQL/Supabase. Los archivos de evidencia se relacionan con el Data Warehouse mediante sus metadatos y URL. La información pasa del esquema operacional al almacén de datos mediante **triggers de la base de datos**, en lugar de utilizar un proceso ETL externo. Estos triggers sincronizan las dimensiones y generan registros en las tablas de hechos cuando ocurren determinadas acciones, como registrar reportes de avance, costos, imágenes o votos ciudadanos.

El modelo de información utiliza un **esquema estrella** compuesto por **diez dimensiones y dos tablas de hechos**. Las dimensiones son: obra, región, empresa, personal, presupuesto, tiempo, tipo de evento, fuente, ciudadano y propuesta. Cinco dimensiones utilizan **SCD Tipo 2** para conservar el historial de cambios: obra, región, empresa, personal y presupuesto. Tres utilizan Tipo 1 y dos Tipo 0. Las dos tablas de hechos son fact_audit_events, cuyo grano es un evento individual de auditoría, y fact_work_monthly, cuyo grano es una obra por mes. La primera registra acciones como creación o modificación de obras, cambios de estado, reportes de avance, costos, modificaciones presupuestales, cargas de imágenes, asignaciones y votos. La segunda almacena por cada obra y mes datos como presupuesto total, costo acumulado, saldo restante, porcentaje ejecutado, avance físico, cantidad de reportes e imágenes, así como si existe retraso y cuántos días de retraso presenta. El sistema puede responder preguntas relacionadas con el seguimiento de las obras públicas. Entre ellas se encuentran cuáles obras presentan retrasos y cuántos días llevan de atraso, qué eventos requieren atención, cómo ha cambiado históricamente una obra, cómo participan los ciudadanos mediante propuestas y votos, cómo se ejecuta el presupuesto según la fuente de financiamiento y qué obras presentan posibles anomalías. Para esto se desarrollaron seis vistas analíticas: obras retrasadas, alertas de auditoría, trazabilidad de obras, participación ciudadana, ejecución presupuestal y detección de anomalías. También se proporciona una interfaz geoespacial donde las obras aparecen ubicadas en un mapa y pueden consultarse indicadores de avance físico y financiero.

Entre las principales limitaciones se encuentra que el sistema no tiene actualmente una implementación dinámica alojada permanentemente y que sus resultados analíticos fueron obtenidos utilizando **datos sintéticos**, debido a restricciones de privacidad para publicar registros municipales reales. Por ello, los resultados no han sido validados con datos reales. También se señala que el almacenamiento de objetos todavía funciona como un repositorio de evidencias y no como un lago analítico consultable, por lo que el sistema todavía no constituye un lakehouse completo. Además, la calidad del análisis depende de la calidad, cobertura y actualización de los datos ingresados por los supervisores.

Como trabajo futuro, los autores proponen evolucionar el sistema hacia una arquitectura **lakehouse**, utilizando formatos abiertos como Apache Iceberg o Parquet que puedan consultarse directamente sobre el almacenamiento de objetos. También plantean incorporar visión por computadora para clasificar automáticamente el avance de las obras mediante fotografías, publicar el esquema como un vocabulario OWL, utilizar un estándar OC4IDS, mejorar el sistema de votación ciudadana, desarrollar modelos de series de tiempo para predecir fechas de terminación, mejorar el criterio de detección de anomalías de costos y validar la arquitectura en otros municipios utilizando datos reales.

Bibliografía

- González Casiano, U., Maldonado Mejía, M. T., y Hurtado Avilés, G. (en prensa). A dimensional data warehouse for geospatial monitoring of municipal public works, with an evolution path toward a lakehouse architecture. En *Advances in Computer Science Applications and Research*. Springer.
- Velázquez Arrieta, E. U., Pulido Morales, O. F., García López, E., Hernández Martínez, C. A., y Hurtado Avilés, G. (en prensa). Territorial information retrieval from heterogeneous open data through the construction of a data warehouse for water management in Mexico City. En *Advances in Computer Science Applications and Research*. Springer.
- Villa Vargas, J. M., Hurtado Avilés, G., y Climent Hernández, J. A. (2026). Cuando México tiembla: la historia contada por los datos. *AZCATL Revista de Divulgación de la Ciencia, la Ingeniería y la Innovación*, 4(6), 28–33. <https://doi.org/10.24275/AZC2026E1004>